

Sekcja 02 - Chronological split and target EDA

? Zakres komorek w notebooku: `26` -> `38`

Pliki i artefakty tej sekcji

? `C:\Users\ankap\OneDrive\Desktop\PROJEKTY\nn\eth-mlp-project\data\labeled\train\_labeled.csv`
(istnieje)

? `C:\Users\ankap\OneDrive\Desktop\PROJEKTY\nn\eth-mlp-project\data\labeled\val\_labeled.csv`
(istnieje)

? `C:\Users\ankap\OneDrive\Desktop\PROJEKTY\nn\eth-mlp-project\data\labeled\test\_labeled.csv`
(istnieje)

? `C:\Users\ankap\OneDrive\Desktop\PROJEKTY\nn\eth-mlp-project\data\labeled\split\_summary.csv`
(istnieje)

?
`C:\Users\ankap\OneDrive\Desktop\PROJEKTY\nn\eth-mlp-project\data\labeled\class\_distribution\_per\_split.csv`
(istnieje)

Wyniki liczbowe / raporty (jesli dostępne)

`split\_summary.csv`

split,rows,ratio_real,start,end

train,32376,0.6999913517253308,2021-01-01 00:00:00+00:00,2024-09-11 13:00:00+00:00

val,6937,0.1499827034506616,2024-09-11 14:00:00+00:00,2025-06-27 14:00:00+00:00

test,6939,0.1500259448240076,2025-06-27 15:00:00+00:00,2026-04-12 17:00:00+00:00

`class\_distribution\_per\_split.csv`

split,target,count,ratio

train,0,8166,0.2522

train,1,15349,0.4741

train,2,8861,0.2737

val,0,1884,0.2716

val,1,3042,0.4385

val,2,2011,0.2899

test,0,1758,0.2534

test,1,3352,0.4831

test,2,1829,0.2636

Komorka po komorce

Cell 26 (markdown)

? Start: `## 02 - Chronological split and target EDA`

? Rola: opis metodologii / komentarz interpretacyjny / naglowek etapu.

? Znaczenie: pomaga powiazac kod z wymaganiami projektu i interpretacja wynikow.

Cell 27 (code)

? Start: `if 'timestamp' not in labeled\_df.columns and labeled\_df.index.name == 'timestamp':`

? Co robi kod: Normalizacja znacznika czasu (UTC), sortowanie i kontrola chronologii.

? Jak to jest wyliczane: krok proceduralny (przekształcenie danych / trenowanie / zapis), bez osobnego wzoru matematycznego w tej komorce.

? Wynik uruchomienia: Brak outputu (komorka definicyjna lub przygotowawcza).

Cell 28 (markdown)

? Start: `### 1. Chronological split train/val/test`

? Rola: opis metodologii / komentarz interpretacyjny / naglowek etapu.

? Znaczenie: pomaga powiazac kod z wymaganiami projektu i interpretacja wynikow.

Cell 29 (code)

? Start: ``TRAIN_RATIO = 0.70``

? Co robi kod: Chronologiczny podzia? train/val/test i raport zakres?w czasowych.

? Jak to jest wyliczane: krok proceduralny (przekształcenie danych / trenowanie / zapis), bez osobnego wzoru matematycznego w tej komorce.

? Wynik uruchomienia: Wynik tabelaryczny/wizualny: HTML (np. Styler).

Cell 30 (markdown)

? Start: ``### 2. Anti-leakage control (time)``

? Rola: opis metodologii / komentarz interpretacyjny / naglowek etapu.

? Znaczenie: pomaga powiazac kod z wymaganiami projektu i interpretacja wynikow.

Cell 31 (code)

? Start: ``split_checks = pd.DataFrame({``

? Co robi kod: Wykonanie kroku pomocniczego w ramach bie??cej sekcji pipeline.

? Jak to jest wyliczane: krok proceduralny (przekształcenie danych / trenowanie / zapis), bez osobnego wzoru matematycznego w tej komorce.

? Wynik uruchomienia: Wynik tabelaryczny/wizualny: HTML (np. Styler).

Cell 32 (markdown)

? Start: ``### 3. Target EDA: per split``

? Rola: opis metodologii / komentarz interpretacyjny / naglowek etapu.

? Znaczenie: pomaga powiazac kod z wymaganiami projektu i interpretacja wynikow.

Cell 33 (code)

? Start: ``def class_distribution(df: pd.DataFrame, split_name: str) -> pd.DataFrame:``

? Co robi kod: Wyliczenie rozk?ad?w klas i proporcji klas per split.

? Jak to jest wyliczane: krok proceduralny (przekształcenie danych / trenowanie / zapis), bez osobnego wzoru matematycznego w tej komorce.

? Wynik uruchomienia: Wynik tabelaryczny/wizualny: HTML (np. Styler). Wynik wizualny: wykres PNG.

Cell 34 (markdown)

? Start: ``### 4. Split Timeline Visualization``

? Rola: opis metodologii / komentarz interpretacyjny / naglowek etapu.

? Znaczenie: pomaga powiazac kod z wymaganiami projektu i interpretacja wynikow.

Cell 35 (code)

? Start: ``plt.figure(figsize=(14, 2.8))``

? Co robi kod: Wykonanie kroku pomocniczego w ramach bie??cej sekcji pipeline.

? Jak to jest wyliczane: krok proceduralny (przekształcenie danych / trenowanie / zapis), bez osobnego wzoru matematycznego w tej komorce.

? Wynik uruchomienia: Wynik wizualny: wykres PNG.

Cell 36 (markdown)

? Start: ``### 5. Data saving``

? Rola: opis metodologii / komentarz interpretacyjny / naglowek etapu.

? Znaczenie: pomaga powiazac kod z wymaganiami projektu i interpretacja wynikow.

Cell 37 (code)

? Start: ``TRAIN_OUT = LABELED_PATH + 'train_labeled.csv'``

? Co robi kod: Wykonanie kroku pomocniczego w ramach bieżącej sekcji pipeline.

? Jak to jest wyliczane: krok proceduralny (przekształcenie danych / trenowanie / zapis), bez osobnego wzoru matematycznego w tej komórce.

? Wynik uruchomienia: Wynik tabelaryczny/wizualny: HTML (np. Styler).

? Zapisuje pliki:

- ``to_csv(CLASS_REPORT_OUT, index=False)``

- ``to_csv(SPLIT_SUMMARY_OUT, index=False)``

- ``to_csv(TEST_OUT, index=False)``

- ``to_csv(TRAIN_OUT, index=False)``

- ``to_csv(VAL_OUT, index=False)``

Cell 38 (code)

? Start: ``train_split_df = train_df.copy()``

? Co robi kod: Wykonanie kroku pomocniczego w ramach bieżącej sekcji pipeline.

? Jak to jest wyliczane: krok proceduralny (przekształcenie danych / trenowanie / zapis), bez osobnego wzoru matematycznego w tej komórce.

? Wynik uruchomienia: Brak outputu (komórka definicyjna lub przygotowawcza).