

Sekcja 04 - Train/Val EDA and multicollinearity

? Zakres komorek w notebooku: `58` -> `75`

Pliki i artefakty tej sekcji

?

`C:\Users\ankap\OneDrive\Desktop\PROJEKTY\nn\eth-mlp-project\data\processed\train\_selected.csv`
(istnieje)

?

`C:\Users\ankap\OneDrive\Desktop\PROJEKTY\nn\eth-mlp-project\data\processed\val\_selected.csv`
(istnieje)

?

`C:\Users\ankap\OneDrive\Desktop\PROJEKTY\nn\eth-mlp-project\data\processed\test\_selected.csv`
(istnieje)

?

`C:\Users\ankap\OneDrive\Desktop\PROJEKTY\nn\eth-mlp-project\data\processed\selected\_feature\_columns.csv`
(istnieje)

?

`C:\Users\ankap\OneDrive\Desktop\PROJEKTY\nn\eth-mlp-project\data\processed\feature\_selection\_report.csv`
(istnieje)

?

`C:\Users\ankap\OneDrive\Desktop\PROJEKTY\nn\eth-mlp-project\data\processed\dropped\_features\_report.csv`
(istnieje)

?

`C:\Users\ankap\OneDrive\Desktop\PROJEKTY\nn\eth-mlp-project\data\processed\feature\_target\_mi.csv`
(istnieje)

? `C:\Users\ankap\OneDrive\Desktop\PROJEKTY\nn\eth-mlp-project\data\processed\vif\_table.csv`
(istnieje)

?

`C:\Users\ankap\OneDrive\Desktop\PROJEKTY\nn\eth-mlp-project\reports\eda\corr\_heatmap\_train\_val.png`
(istnieje)

Wyniki liczbowe / raporty (jesli dostępne)

`feature\_selection\_report.csv`

metric,value

initial_feature_count,96

dropped_constant_count,0

dropped_corr_count,37

dropped_vif_count,21

final_selected_count,38

Komorka po komorce

Cell 58 (markdown)

? Start: `## 04 - Train/Val EDA and multicollinearity`

? Rola: opis metodologii / komentarz interpretacyjny / naglowek etapu.

? Znaczenie: pomaga powiazac kod z wymaganiami projektu i interpretacja wynikow.

Cell 59 (markdown)

? Start: `### 1. Histograms and pairplot (train+val only)`

? Rola: opis metodologii / komentarz interpretacyjny / naglowek etapu.

? Znaczenie: pomaga powiazac kod z wymaganiami projektu i interpretacja wynikow.

Cell 60 (code)

? Start: ``# due to a large number of features (96) only a few histograms are displayed``

? Co robi kod: Definicja funkcji feature engineering (cechy techniczne, momentum, zmienno??, lags, rolling).

? Jak to jest wyliczane: krok proceduralny (przekształcenie danych / trenowanie / zapis), bez osobnego wzoru matematycznego w tej komorce.

? Wynik uruchomienia: Wynik wizualny: wykres PNG.

Cell 61 (markdown)

? Start: ``### Wnioski``

? Rola: opis metodologii / komentarz interpretacyjny / naglowek etapu.

? Znaczenie: pomaga powiazac kod z wymaganiami projektu i interpretacja wynikow.

Cell 62 (markdown)

? Start: ``### 2. Feature covariance and high-correlation filter``

? Rola: opis metodologii / komentarz interpretacyjny / naglowek etapu.

? Znaczenie: pomaga powiazac kod z wymaganiami projektu i interpretacja wynikow.

Cell 63 (code)

? Start: ``def drop_constant_features(df: pd.DataFrame, min_unique: int = 2):``

? Co robi kod: Filtracja cech sta?ych i silnie skorelowanych + heatmapa korelacji.

? Jak to jest wyliczane: krok proceduralny (przekształcenie danych / trenowanie / zapis), bez osobnego wzoru matematycznego w tej komorce.

? Wynik uruchomienia: Wynik wizualny: wykres PNG. Wynik tabelaryczny/wizualny: HTML (np. Styler).

Cell 64 (markdown)

? Start: ``##### Wnioski``

? Rola: opis metodologii / komentarz interpretacyjny / naglowek etapu.

? Znaczenie: pomaga powiazac kod z wymaganiami projektu i interpretacja wynikow.

Cell 65 (markdown)

? Start: ``### 3. VIF analysis``

? Rola: opis metodologii / komentarz interpretacyjny / naglowek etapu.

? Znaczenie: pomaga powiazac kod z wymaganiami projektu i interpretacja wynikow.

Cell 66 (code)

? Start: ``def reduce_vif_features(``

? Co robi kod: Iteracyjna redukcja wielokolinearno?ci metod? VIF.

? Jak to jest wyliczane: krok proceduralny (przekształcenie danych / trenowanie / zapis), bez osobnego wzoru matematycznego w tej komorce.

? Wynik uruchomienia: Log/stream:

c:\Users\ankap\OneDrive\Desktop\PROJEKTY\mn\eth-mlp-project\venv\Lib\site-packages\statsmodels\stats\outliers.py:100: RuntimeWarning: divide by zero encountered in scalar divide | vif = 1. / (1. - r_squared_i) Wynik tabelaryczny/wizualny: HTML (np. Styler).

Cell 67 (markdown)

? Start: ``### 4. Feature-target relation (train+val)``

? Rola: opis metodologii / komentarz interpretacyjny / naglowek etapu.

? Znaczenie: pomaga powiazac kod z wymaganiami projektu i interpretacja wynikow.

Cell 68 (code)

? Start: `X_mi = X_no_corr[kept_after_vif].copy()`

? Co robi kod: Analiza relacji cecha-target przez Mutual Information.

? Jak to jest wyliczane: krok proceduralny (przekształcenie danych / trenowanie / zapis), bez osobnego wzoru matematycznego w tej komorce.

? Wynik uruchomienia: Wynik tabelaryczny/wizualny: HTML (np. Styler). Wynik wizualny: wykres PNG.

Cell 69 (markdown)

? Start: `##### Wnioski`

? Rola: opis metodologii / komentarz interpretacyjny / naglowek etapu.

? Znaczenie: pomaga powiazac kod z wymaganiami projektu i interpretacja wynikow.

Cell 70 (markdown)

? Start: `### 5. Final selected feature set & apply to train/val/test`

? Rola: opis metodologii / komentarz interpretacyjny / naglowek etapu.

? Znaczenie: pomaga powiazac kod z wymaganiami projektu i interpretacja wynikow.

Cell 71 (code)

? Start: `selected_features = kept_after_vif.copy()`

? Co robi kod: Budowa finalnej listy cech wejsciowych i finalnych splitow cechowych.

? Jak to jest wyliczane: krok proceduralny (przekształcenie danych / trenowanie / zapis), bez osobnego wzoru matematycznego w tej komorce.

? Wynik uruchomienia: Wynik tabelaryczny/wizualny: HTML (np. Styler).

Cell 72 (markdown)

? Start: `##### Wnioski`

? Rola: opis metodologii / komentarz interpretacyjny / naglowek etapu.

? Znaczenie: pomaga powiazac kod z wymaganiami projektu i interpretacja wynikow.

Cell 73 (markdown)

? Start: `### 6. Saving artifacts`

? Rola: opis metodologii / komentarz interpretacyjny / naglowek etapu.

? Znaczenie: pomaga powiazac kod z wymaganiami projektu i interpretacja wynikow.

Cell 74 (code)

? Start: `TRAIN_SELECTED_OUT = PROCESSED_PATH + 'train_selected.csv'`

? Co robi kod: Wykonanie kroku pomocniczego w ramach biecej sekcji pipeline.

? Jak to jest wyliczane: krok proceduralny (przekształcenie danych / trenowanie / zapis), bez osobnego wzoru matematycznego w tej komorce.

? Wynik uruchomienia: Wynik tabelaryczny/wizualny: HTML (np. Styler).

? Zapisuje pliki:

- `to_csv(DROP_LIST_OUT, index=False)`
- `to_csv(MI_REPORT_OUT, index=False)`
- `to_csv(SELECTED_FEATURES_OUT, index=False)`
- `to_csv(SELECTION_REPORT_OUT, index=False)`
- `to_csv(TEST_SELECTED_OUT, index=False)`
- `to_csv(TRAIN_SELECTED_OUT, index=False)`
- `to_csv(VAL_SELECTED_OUT, index=False)`
- `to_csv(VIF_REPORT_OUT, index=False)`

Cell 75 (code)

? Start: `train_df = train_selected.copy()`

? Co robi kod: Wykonanie kroku pomocniczego w ramach bieżącej sekcji pipeline.

? Jak to jest wyliczane: krok proceduralny (przekształcenie danych / trenowanie / zapis), bez osobnego wzoru matematycznego w tej komórce.

? Wynik uruchomienia: Brak outputu (komórka definicyjna lub przygotowawcza).