

Sekcja 05 - Scaling and DataLoaders

? Zakres komorek w notebooku: `76` -> `88`

Pliki i artefakty tej sekcji

?

`C:\Users\ankap\OneDrive\Desktop\PROJEKTY\nn\eth-mlp-project\data\processed\selected\_scaler.pkl`
(istnieje)

?

`C:\Users\ankap\OneDrive\Desktop\PROJEKTY\nn\eth-mlp-project\data\processed\class\_weights.csv`
(istnieje)

?

`C:\Users\ankap\OneDrive\Desktop\PROJEKTY\nn\eth-mlp-project\data\processed\scaled\_arrays.npz`
(istnieje)

?

`C:\Users\ankap\OneDrive\Desktop\PROJEKTY\nn\eth-mlp-project\data\processed\scaling\_dataloaders\_summary.json`
(istnieje)

Wyniki liczbowe / raporty (jesli dostepne)

`scaling\_dataloaders\_summary.json`

```
{
  "scaler_type": "robust",
  "auto_scaler": "robust",
  "train_outlier_ratio_iqr": 0.05518289009661442,
  "selected_feature_count": 38,
  "train_shape": [
    32326,
    38
  ],
  "val_shape": [
    6937,
    38
  ],
  "test_shape": [
    6939,
    38
  ],
  "batch_size": 128,
  "use_weighted_sampler": false,
  "class_weights": {
    "0": 1.3216402960055604,
    "1": 0.7030295121898176,
    "2": 1.2181023438088778
  }
}
```

Komorka po komorce

Cell 76 (markdown)

? Start: `## 05 - Scaling and DataLoaders`

? Rola: opis metodologii / komentarz interpretacyjny / naglowek etapu.

? Znaczenie: pomaga powiazac kod z wymaganiami projektu i interpretacja wynikow.

Cell 77 (markdown)

? Start: `### 1. Building X/y and choosing scaler`

? Rola: opis metodologii / komentarz interpretacyjny / naglowek etapu.

? Znaczenie: pomaga powiazac kod z wymaganiami projektu i interpretacja wynikow.

Cell 78 (code)

? Start: `X_train = train_df[selected_features].to_numpy(dtype=np.float32)`

? Co robi kod: Wykonanie kroku pomocniczego w ramach biecej sekcji pipeline.

? Jak to jest wyliczane: krok proceduralny (przekształcenie danych / trenowanie / zapis), bez osobnego wzoru matematycznego w tej komorce.

? Wynik uruchomienia: Wynik tabelaryczny/wizualny: HTML (np. Styler).

Cell 79 (markdown)

? Start: `### 2. Anti-leakage scaling`

? Rola: opis metodologii / komentarz interpretacyjny / naglowek etapu.

? Znaczenie: pomaga powiazac kod z wymaganiami projektu i interpretacja wynikow.

Cell 80 (code)

? Start: `# Fit scaler only on train, then transform val/test.`

? Co robi kod: Skalowanie anti-leakage: fit na train, transform na val/test.

? Jak to jest wyliczane:

- skaler dopasowany tylko na train: `X_train_scaled = fit_transform(X_train)`, `val/test = transform`

? Wynik uruchomienia: Wynik tabelaryczny/wizualny: HTML (np. Styler).

Cell 81 (markdown)

? Start: `### 3. Class imbalance setup`

? Rola: opis metodologii / komentarz interpretacyjny / naglowek etapu.

? Znaczenie: pomaga powiazac kod z wymaganiami projektu i interpretacja wynikow.

Cell 82 (code)

? Start: `class_counts = np.bincount(y_train)`

? Co robi kod: Wyliczenie wag klas dla niezbalansowanej klasyfikacji.

? Jak to jest wyliczane:

- `class_weight_c = N / (K * n_c)`

? Wynik uruchomienia: Wynik tabelaryczny/wizualny: HTML (np. Styler).

Cell 83 (markdown)

? Start: `### 4. Dataset and DataLoader`

? Rola: opis metodologii / komentarz interpretacyjny / naglowek etapu.

? Znaczenie: pomaga powiazac kod z wymaganiami projektu i interpretacja wynikow.

Cell 84 (code)

? Start: `class TabularDataset(Dataset):`

? Co robi kod: Definicja datasetu tablicowego i DataLoader w PyTorch.

? Jak to jest wyliczane: krok proceduralny (przekształcenie danych / trenowanie / zapis), bez osobnego wzoru matematycznego w tej komorce.

? Wynik uruchomienia: Wynik tabelaryczny/wizualny: HTML (np. Styler).

Cell 85 (markdown)

? Start: `### 5. Sanity check batches`

? Rola: opis metodologii / komentarz interpretacyjny / naglowek etapu.

? Znaczenie: pomaga powiazac kod z wymaganiami projektu i interpretacja wynikow.

Cell 86 (code)

? Start: ``x_batch, y_batch = next(iter(train_loader))``

? Co robi kod: Wykonanie kroku pomocniczego w ramach bieżącej sekcji pipeline.

? Jak to jest wyliczane: krok proceduralny (przekształcenie danych / trenowanie / zapis), bez osobnego wzoru matematycznego w tej komorce.

? Wynik uruchomienia: Wynik tabelaryczny/wizualny: HTML (np. Styler).

Cell 87 (markdown)

? Start: ``### 6. Save preprocessing artifacts``

? Rola: opis metodologii / komentarz interpretacyjny / naglowek etapu.

? Znaczenie: pomaga powiazac kod z wymaganiami projektu i interpretacja wynikow.

Cell 88 (code)

? Start: ``SCALER_OUT = PROCESSED_PATH + 'selected_scaler.pkl``

? Co robi kod: Zapis artefaktu w preprocessingu (scaler, arrays, class weights, summary).

? Jak to jest wyliczane: krok proceduralny (przekształcenie danych / trenowanie / zapis), bez osobnego wzoru matematycznego w tej komorce.

? Wynik uruchomienia: Wynik tabelaryczny/wizualny: HTML (np. Styler).

? Zapisuje pliki:

- ``to_csv(CLASS_WEIGHTS_OUT, index=False)``